TECMILENIO

Análisis comparativo de modelos para identificar e implementar el modelo preentrenado más adecuado para un caso de uso específico.

Next Best Offer (NBO) para productos y generación de argumento de venta.

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	Identificar e implementar el modelo preentrenado más adecuado para un caso de uso específico.
Alumno(a):	*ROGELIO ACO GONZALEZ*
Matrícula:	*2987969*
Docente:	*LUIS ARIEL VAZQUEZ PIÑA*
Fecha de entrega:	*2/ NOV /2026*

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	■ Sí ☐ No	● Determinar los modelos a usar en la comparación ● Realizar la programación de los modelos ● Determinación de riesgos, umbrales y ajustes mínimos
Claude (Anthropic)	☐ Sí ☐ No	
Gemini (Google)	☐ Sí ☐ No	
Copilot (Microsoft)	☐ Sí ☐ No	
Otra (especifica):	☐ Sí ☐ No	

ACTIVIDAD 4

Gestión de proyectos de inteligencia artificial

Antecedentes

En los ejercicios anteriores se venía trabajando con un modelo de Next Best Offer (NBO) para un banco y adicionalmente se buscaba generar a través de inteligencia artificial generativa un argumento de recomendación para ayudar al ejecutivo a vender el producto.

Al revisar la información de datos existentes en Hugging face se identificó que existe información de bancos pero corresponde a operaciones bancarias de consultas o transferencias, lo cuál claramente se enfoca en la operativa de un banco pero no en un modelo de recomendación de productos, de igual manera se logró identificar un dataset relacionado con la venta de productos en Amazon y decidí continuar con el modelo de NBO aunque sea aplicado en otra industria.

Objetivo

Identificar e implementar el modelo preentrenado más adecuado para un caso de uso específico.

El caso de uso seleccionado es referente a un modelo NBO en el área de comercios Retail, aprovechando la información que existe de reseñas reales de Amazon en Hugging face.

Se trabajó con 3 modelos que resuelven la necesidad del NBO y se evaluaron sus métricas de desempeño.

Una vez que se ha identificado el producto, se utiliza un modelo adicional para la generación del texto que servirá al ejecutivo o vendedor como argumento de convencimiento para la venta del producto. Considero relevante mencionar que el argumento de venta no altera la prioridad establecida por el modelo NBO, y no es una instrucción definitiva, es un elemento de apoyo para el vendedor y este puede utilizarlo o no y generar un comentario acerca de que tanto le fue de utilidad.

Resumen ejecutivo

Se implementó un prototipo académico de Next Best Offer (NBO) para priorizar productos a partir de historiales de interacción de Amazon Reviews 2023, utilizando la categoría All_Beauty. Se utilizaron tres modelos del tipo Transformer, a los cuales se les puntuó afinidad semántica entre perfiles y productos. Un

modelo adicional, el Qwen generó un argumento comercial sujeto a controles de seguridad y revisión humana (huma in the loop).

De los tres modelos comparados, MultiQA-MiniLM fue seleccionado exclusivamente por su HitRate@1 de validación (52.50%). En prueba obtuvo 41.25%, por debajo de MiniLM y de la referencia de popularidad (ambos 46.25%). En base al análisis realizado se considera que el prototipo es funcional, pero no garantiza superioridad comercial frente a una referencia sencilla.

Caso de uso y alcance

Para el desarrollo de esta actividad, se ha seleccionado una necesidad real que se tiene en el ámbito del retail, que si bien puede utilizarse para muchas otras empresas o industrias, al analizarla a detalle se observa que tiene sus propias variantes.

El proyecto continúa la arquitectura NBO Assist GenAI: un motor prioriza una oferta y una capa generativa prepara una explicación para revisión humana. En esta actividad el catálogo es de productos de consumo, no financieros. La afinidad semántica no representa elegibilidad, propensión calibrada, ni probabilidad de contratación.

Ecosistema Hugging Face y datos

Hugging face aporta los tres modelos de embeddings y Qwen; de igual manera en Dataset se aloja el conjunto de Amazon.

Se descargaron las particiones oficiales train/valid/test del benchmark 0core/last_out_w_his y metadatos All_Beauty. La muestra evaluada contiene 80 grupos y 400 pares por partición de validación y prueba.

Los campos originales del dataset son:

- user_id, parent_asin
- Rating
- Timestamp
- History

Para comprobar que los modelos podrían recomendar correctamente un producto, para cada grupo se formó un perfil con historial, un producto objetivo con rating >=4 (que significa que el usuario lo valoró positivamente y le puso 4 o 5 estrellas) y cuatro productos no observados. La etiqueta binaria es una aproximación: ausencia de interacción no equivale a rechazo. Me parece importante reiterar que los productos no observados corresponden a productos de los cuales no tenemos referencia, es decir el cliente no ha indicado si son de su agrado o no, sólo un producto de cada grupo de 5 tiene una referencia por parte del cliente. Esto será importante cuando tengamos que evaluar los resultados de las métricas.

El objetivo de este experimento es comprobar si el modelo consigue recomendar el producto con alto rating que el usuario ya tenía valorado.

Los programas se ejecutaron en Goggle colab con GPU T4.

Modelos y criterios de selección

Criterios: compatibilidad con GPU T4, calidad de ranking (HitRate@1), accuracy/precision/recall/F1 binarios, latencia, memoria, reproducibilidad y licencia. Se emplearon modelos públicos preentrenados. El umbral binario exploratorio fue 0.5 y la decisión de NBO se hizo por máximo score coseno entre cinco candidatos.

Los tres modelos preentranados que se utilizaron son:

MiniLM-L6

Modelo ligero y eficiente que convierte textos en representaciones numéricas (embeddings). Nos permite calcular la similitud semántica entre las preferencias del cliente y las características de los productos, con bajo consumo de recursos.

MPNet-base

Modelo que genera representaciones semánticas de mayor dimensión para identificar relaciones entre textos. Ofrece una alternativa de mayor capacidad, aunque requiere más recursos computacionales.

MultiQA-MiniLM

Modelo especializado en recuperación semántica, diseñado para identificar información relevante respecto a una consulta. En nuestro NBO permite comparar el perfil del cliente con los productos disponibles y priorizarlos según su afinidad.

Resultados experimentales

Para este análisis utilizamos un par de grupos de datos para validar al modelo preentrenado, primero un grupo pequeño y controlado de validación y luego utilizamos un grupo mayor para prueba. A ambos grupos se les aplicaron las métricas de efectividad y los resultados fueron los siguientes:

1 Grupo de Validación

Modelo	Accuracy	Precision	Recall	F1	Hit@1
MiniLM-L6	82.50%	65.62%	26.25%	37.50%	47.50%
MPNet-base	81.50%	57.89%	**27.50%**	37.29%	43.75%
MultiQA-MiniLM	**83.50%**	**76.92%**	25.00%	**37.74%**	**52.50%**

La tabla anterior la debemos interpretar así:

MiniLM-L6

Obtuvo 82.5% de accuracy, pero solamente identificó 26.25% de los positivos. Sin embargo, consiguió colocar el producto positivo en primer lugar en 47.5% de los grupos. Esto significa que su capacidad para ordenar productos fue mejor que su capacidad para clasificarlos como positivos utilizando el umbral establecido.

MPNet-base

Obtuvo el recall más alto de los tres: 27.5%. Pero su Hit@1 fue de 43.75%, inferior al de MiniLM y MultiQA. Esto indica que identificar más positivos mediante clasificación no garantiza colocarlos correctamente en la primera posición.

MultiQA-MiniLM

Fue el mejor en accuracy, precision, F1 y Hit@1. Su Hit@1 de 52.5% significa que colocó el producto positivo en primer lugar en: $80 \times 0.525 = 42 grupos.$ De los 80 grupos evaluados, acertó en 42.

El criterio principal de decisión para este caso sería Hit@1, porque para un NBO que tiene como objetivo mostrar sólo la oferta mejor priorizada, se desea saber si el producto relevante aparece en la primera posición.

Bajo este criterio junto con los otros indicadores MultiQA fue seleccionado en este proceso de validación. No porque fuera el mejor en todas las dimensiones, sino porque obtuvo el mejor resultado en la métrica que se ha determinado como métrica principal.

2 Grupo de Prueba

Modelo	Accuracy	Precision	Recall	F1	Hit@1
MiniLM-L6	**82.50%**	67.86%	23.75%	35.19%	**46.25%**
MPNet-base	81.00%	54.17%	**32.50%**	**40.62%**	40.00%
MultiQA-MiniLM	**82.50%**	**72.73%**	20.00%	31.37%	41.25%

Aquí, en la revisión del conjunto de prueba se observa que los resultados cambiaron, ahora **el modelo MiniLM-L6 es el que tiene mejor calificación en el Hit@1**, lo que significa que no hay gran estabilidad en las puntuaciones, aunque esto no debe considerarse como un error, lo que nos indica es que la elección inicial necesita más evidencia antes de convertirse en una recomendación definitiva para negocio

3 Eficiencia en prueba

Modelo	Latencia ms/par	Memoria GPU GB
MiniLM-L6	1.453	0.207
MPNet-base	5.907	0.739
MultiQA-MiniLM	1.420	0.207

La latencia representa el tiempo promedio de inferencia por par en esta ejecución, sin confundirla con el tiempo de carga del modelo. La memoria GPU es la asignación máxima observada en PyTorch, no el consumo total del sistema ni un costo monetario.

Regresando a la idea de poner esto en un banco debe considerarse que en un banco la cantidad de operaciones que se realiza es enorme, que los clientes no entran a la app del banco a realizar operaciones y a distraerse, normalmente desean realizar sus operaciones con rapidez, por lo que un elemento clave en la decisión del modelo sería la latencia o tiempo de espera. Tratándose de un comercio en dónde la gente disfruta revisando ropa o diversos productos este elemento podría no ser tan decisivo.

Recomendación técnica

MultiQA-MiniLM fue seleccionado durante la etapa de validación por obtener el mayor HitRate@1 (52.50%). Sin embargo, en la evaluación de prueba su desempeño bajó un poco a 41.25%, mientras que MiniLM-L6 obtuvo 46.25%, con una latencia baja y un consumo de memoria similar.

Esto deja un trabajo por realizar, porque utilizando la metodología, el modelo adecuado es el MultiQA-MiniLM, pero revisando los resultados con los datos de prueba, considero que MiniLM-L6 es una alternativa interesante para continuar investigando, ya que presentó un comportamiento más consistente entre validación y prueba.

Mencioné ligeramente al inicio de documento la referencia de popularidad, y me parece importante mencionar que en el programa se agregó una métrica basada en los productos que tienen mayores referencias de los clientes y se identificó como la “referencia de popularidad”, la cual servirá como referencia de medición sin utilizar la sofisticación de modelos analíticos.

Y continuando con lo anterior, MiniLM-L6 igualó el desempeño del modelo de referencia basado en popularidad, por lo que todavía no existe evidencia suficiente para afirmar que los modelos semánticos evaluados generan una mejora comercial.

Por tanto, mantendría MultiQA-MiniLM como la selección original del experimento, pero priorizaría MiniLM-L6 en una siguiente fase de evaluación, ampliando la muestra y comparándola nuevamente con modelos de referencia antes de recomendar su implementación.

Riesgos, umbrales y ajustes mínimos

Riesgo	Control propuesto
Sesgo y datos proxy	Ampliar muestra y documentar cobertura; no confundir ratings con conversiones.
Fuga temporal	Auditar timestamps e historiales; usuarios compartidos no prueban por sí solos fuga.
Argumentos inventados	Bloqueo por reglas y revisión humana; atributos verificables antes de comunicar beneficios.
Calidad insuficiente	No desplegar sin superar baseline y umbrales aprobados por negocio.
Privacidad	No publicar tokens ni IDs originales; pseudonimizar y revisar datos exportados.

Umbrales propuestos para una futura prueba piloto (no alcanzados ni aprobados): HitRate@1 superior a popularidad de forma estadísticamente robusta, cero afirmaciones comerciales no sustentadas en muestras auditadas y 100% de argumentos sujetos a aprobación humana antes de uso.

Reproducibilidad y limitaciones

El notebook de Google colab se ha integrado en la entrega final del trabajo y es 100% reproducible.

Conclusión

La actividad nos ha permitido demostrar que técnicamente se pueden realizar un ejercicio con diferentes modelos comparables entre sí, que el proceso puede ser eficiente porque se pueden utilizar modelos preentrenados y que se pueden realizar mediciones formales para determinar cual modelo ofrece los mejores resultados. También permitió observar que las diferentes métricas en sí mismas no determinan cuál es el modelo a elegir, no siempre un modelo tiene todas las mejores calificaciones en todos los aspectos. Es muy importante entender la necesidad y caso de uso para determinar cuál de las métricas será la que debe tener mayor peso en la decisión al momento de seleccionar el modelo.

Otro aprendizaje muy importante es que un NBO generado con algoritmos sofisticados de inteligencia artificial, no necesariamente supera una referencia simple, es decir la referencia de popularidad.

Hay una fuerte dependencia de los datos con los que se cuente, la siguiente etapa empresarial requeriría mejores etiquetas, pruebas controladas, gobernanza y revisión humana.

Referencias bibliográficas

- McAuley Lab. (s. f.). Amazon Reviews 2023 [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/McAuley-Lab/Amazon-Reviews-2023
- Qwen. (s. f.). Qwen2.5-0.5B-Instruct [Modelo de inteligencia artificial]. Hugging Face. https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct
- Sentence Transformers. (s. f.-a). all-MiniLM-L6-v2 [Modelo de inteligencia artificial]. Hugging Face. https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2
- Sentence Transformers. (s. f.-b). all-mpnet-base-v2 [Modelo de inteligencia artificial]. Hugging Face. https://huggingface.co/sentence-transformers/all-mpnet-base-v2
- Sentence Transformers. (s. f.-c). multi-qa-MiniLM-L6-cos-v1 [Modelo de inteligencia artificial]. Hugging Face. https://huggingface.co/sentence-transformers/multi-qa-MiniLM-L6-cos-v1
- Universidad Tecmilenio. (2026a). M5 T09: Selección de modelos preentrenados [Material del curso].
- Universidad Tecmilenio. (2026b). M5 T10: Enfoques de diseño y planeación en IA [Material del curso].